Анализ датасета CSE-CIC-IDS2018

Выявление сетевых атак в облачной инфраструктуре

ВЫЗОВЫ BIG DATA

Объем и память

16.2 миллионов строк. Проект требует оптимизации обработки для предотвращения ошибок переполнения памяти.

Аномалии сбора

Наличие Infinity и "битых" сокетов (порт 0). Необходима верификация данных перед подачей в ML-модель.

ИНФРАСТРУКТУРА AWS

Максимальная реалистичность трафика за счет облачного моделирования:

- 450 узлов-целей и 30 серверов
- Выделенная сеть из 50 атакующих
- Трафик современных протоколов (HTTPS)

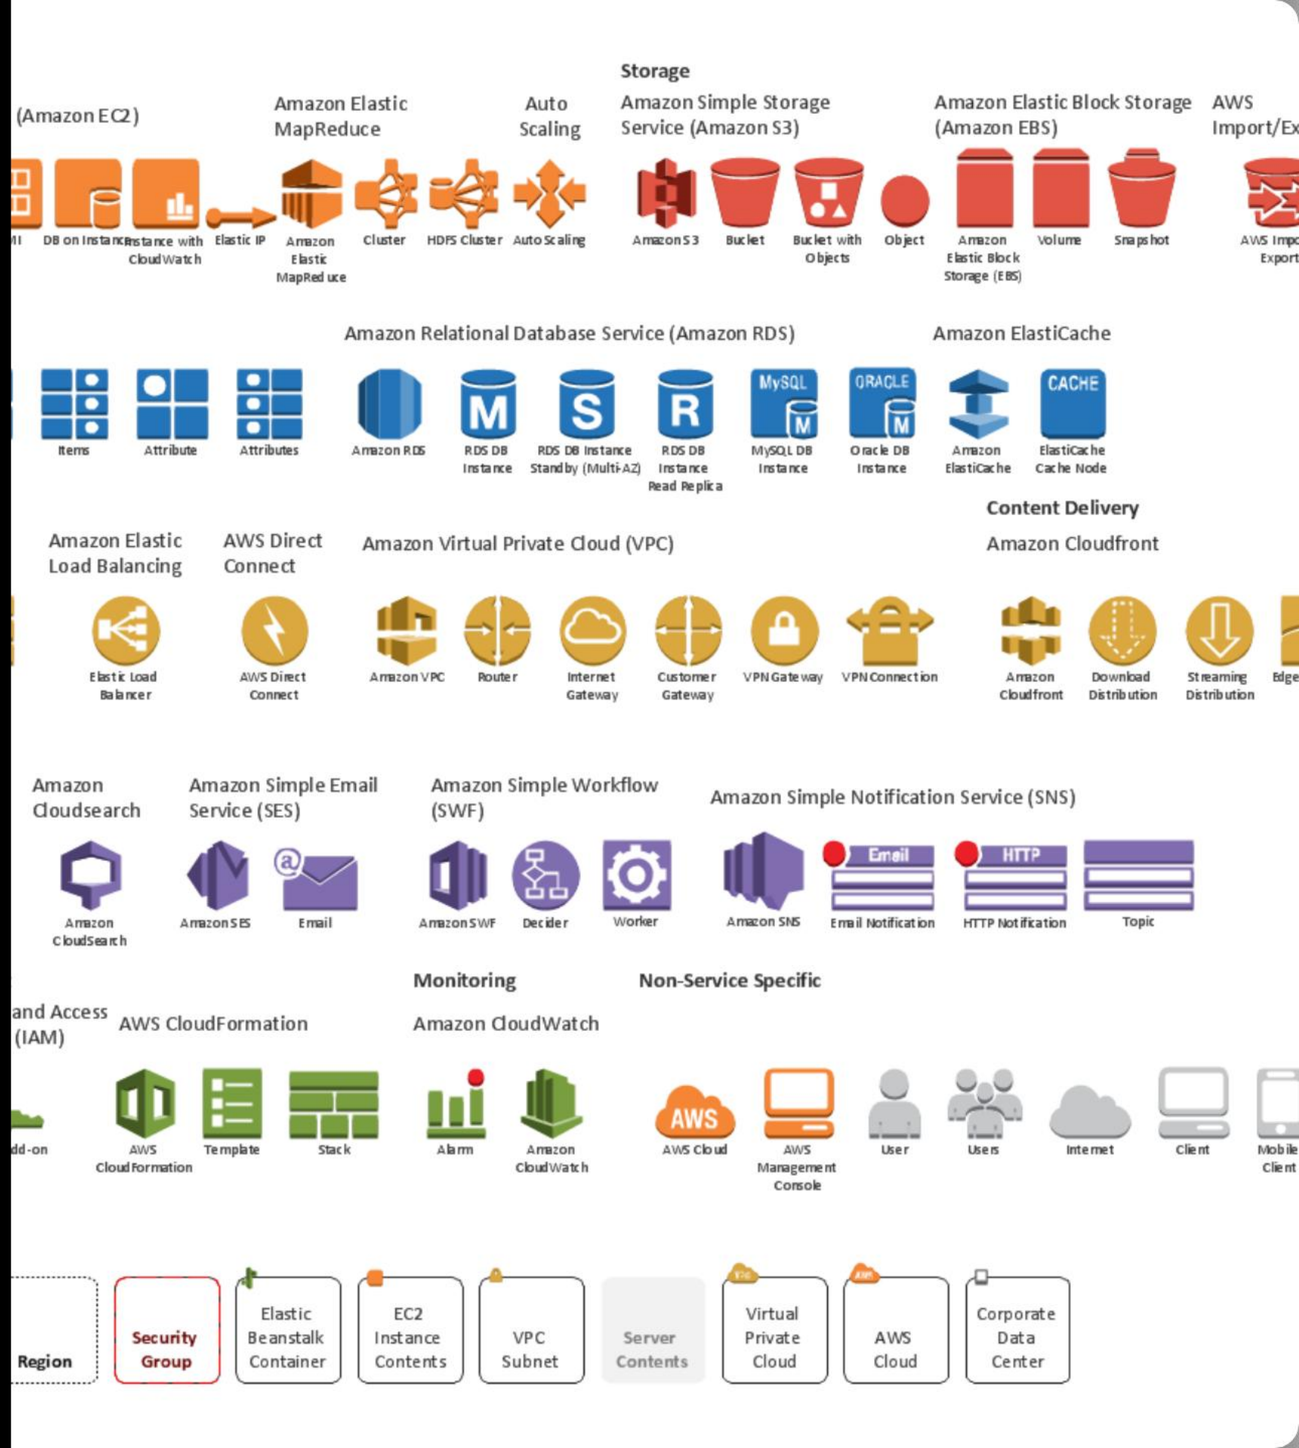

IDS 2017 VS IDS 2018

Параметр	CICIDS2017	CSE-CIC-IDS2018
Объем сессий	~2.83 млн	**~16.23 млн** (рост 6x)
Среда сбора	Локальная сеть	**Облако Amazon (AWS)**
Длительность	5 дней	**10 дней**
Фичи (Max)	80 признаков	**83 признака**

КОМАНДА И РОЛИ

Data-Инженер

Чистка NaN/Inf, удаление константных полей.

Аналитик ИБ

Топология AWS, валидация атак.

ML-Инженер

Feature Importance, балансировка.

Визуализатор

Графы атак и финальные отчеты.

ОПТИМИЗАЦИЯ ПРИЗНАКОВ

Глубокая трансформация

Удаление констант: Исключение признаков с нулевой дисперсией.

Математическая чистка: Устранение NaN/Inf в скоростях потоков.

Логическая фильтрация: Удаление артефактов (TotLen=0).

В результате отобрано 61 наиболее информативное поле.

ВОРОНКА ОЧИСТКИ

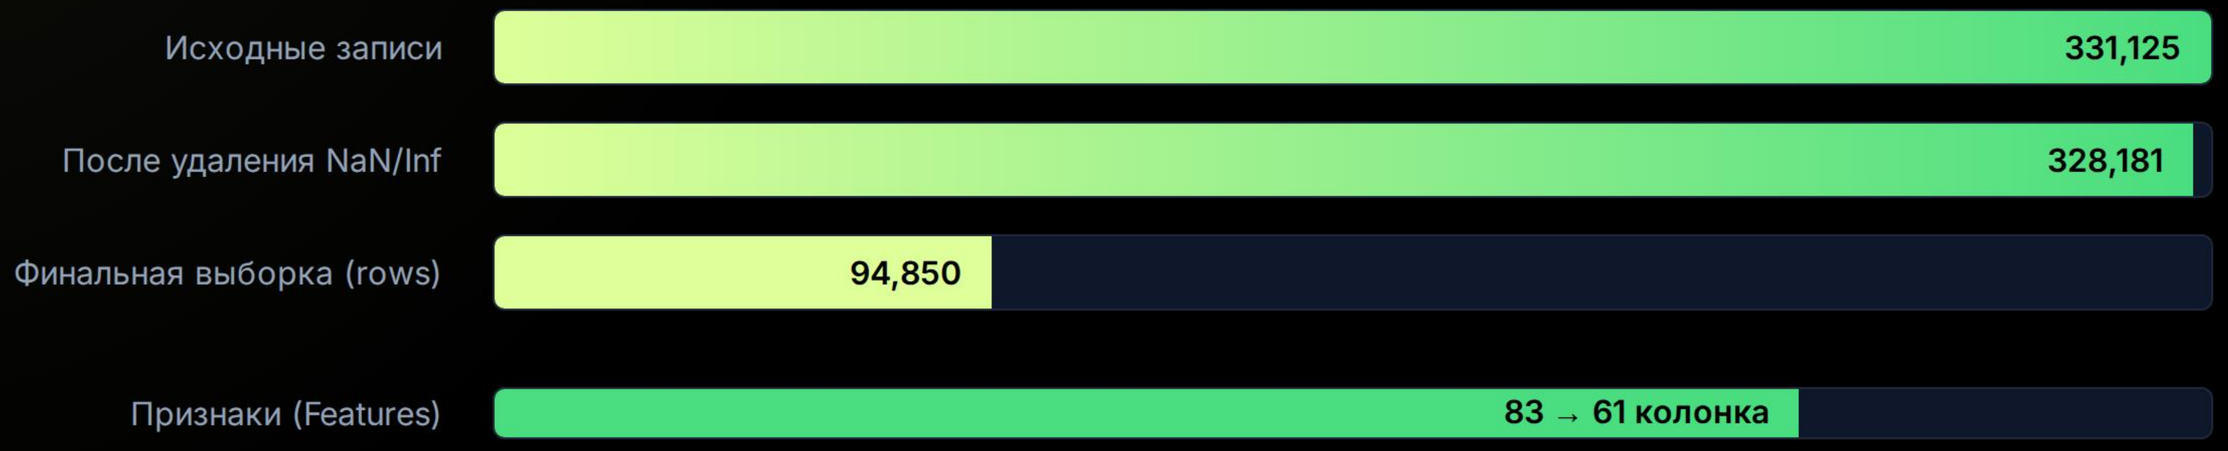

Итоговое сокращение размерности позволило снизить зашумленность данных на 71%.

ДИСБАЛАНС КЛАССОВ

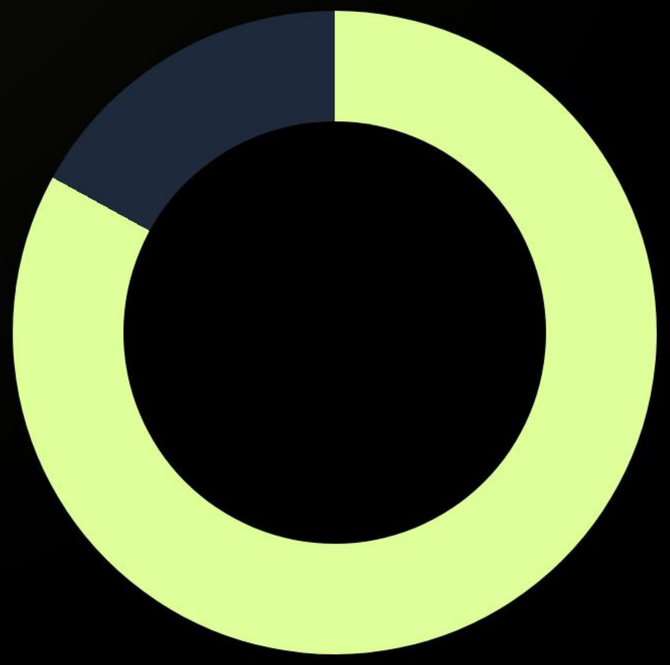

Attacks (17%)

Резкий перекос в сторону нормального трафика требует применения SMOTE перед обучением ML-классификаторов.

ИТОГИ И ИНСАЙТЫ

- **Минимизация шума:** Оставлена 61 колонка с максимальной предсказательной способностью.
- **Чистота выборки:** Удаление 71% записей ликвидировало "нулевой" трафик, искажающий метрики обучения.
- **План на ML:** Переход к Random Forest для классификации сетевых вторжений на верифицированной базе.

Вопросы?

Готовы обсудить технические детали очистки

IMAGE SOURCES

https://static.vecteezy.com/system/resources/thumbnails/066/833/192/small/futuristic-digital-background-with-glowing-lines-and-circuit-elements-ideal-for-technology-data-and-cybersecurity-themes-hightech-style-with-green-light-abstract-design-illustration-vector.jpg

Source: www.vecteezy.com

---

https://www.conceptdraw.com/How-To-Guide/picture/Design%20Elements%20-%20AWS%20-%20Amazon%20Web%20Services%20architecture%20solution-2_0.png

Source: www.conceptdraw.com

---

https://static.vecteezy.com/system/resources/thumbnails/072/502/810/small/abstract-network-connections-with-glowing-nodes-and-lines-futuristic-digital-data-flow-photo.jpg

Source: www.vecteezy.com

---

https://swimlane.com/wp-content/uploads/SOC-BUILD_Masthead.png

Source: swimlane.com