Анализ датасета CSE-CIC-IDS2018

Разбор аномалий и глубокая оптимизация признаков

ВЫЗОВЫ BIG DATA

Масштабируемость

16.2 миллионов строк. Проблема нехватки памяти при стандартной обработке в Python (pandas).

Техногенный мусор

Infinity и NaN значения. Артефакты сбора CICFlowMeter и некорректные сессии (порты 0).

СРЕДА AWS

В отличие от лабораторных данных, IDS2018 имитирует облачную инфраструктуру:

- 450 ПК-жертв и 30 серверов
- 50 узлов атакующей сети
- Смешанный фоновый трафик

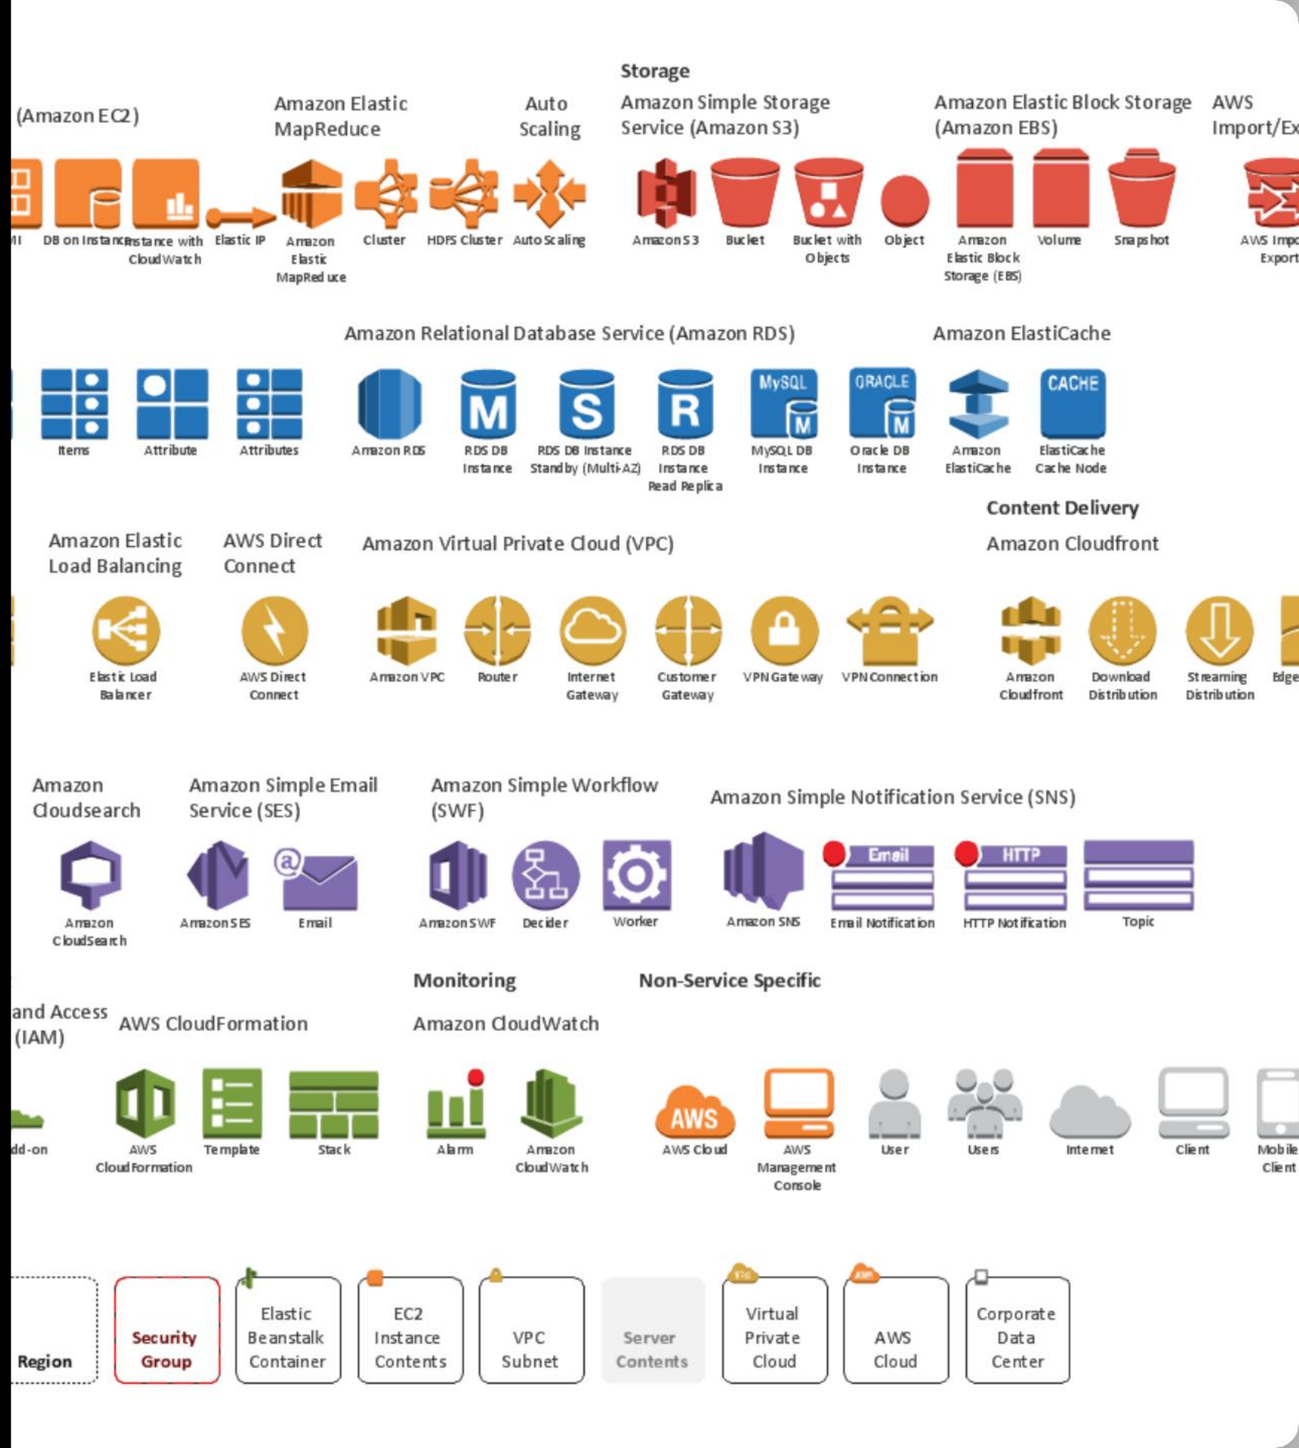

КОМАНДА И РОЛИ

Data-Инженер

Очистка NaN/Inf, удаление константных признаков.

Аналитик ИБ

Топология AWS, валидация таймлайнов атак.

ML-Инженер

Feature Importance, балансировка выборки.

Визуализатор

Создание графов атак и инфографики.

СРАВНЕНИЕ 2017 VS 2018

Параметр	CICIDS2017	CSE-CIC-IDS2018
Объем сессий	~2.83 млн	**~16.23 млн** (в 6 раз больше)
Инфраструктура	Локальная сеть	**Облако AWS** (реальный масштаб)
Длительность	5 дней	**10 дней**
Протоколы	Базовые	Современные (вкл. HTTPS)

ОПТИМИЗАЦИЯ ПРИЗНАКОВ

Глубокая очистка данных

Удаление констант: Исключены столбцы с нулевой дисперсией (не несут информации).

Математическая чистка: Ликвидация NaN/Inf в скоростных параметрах.

Логический фильтр: Удаление артефактов (TotLen=0).

ВОРОНКА ОЧИСТКИ

Удаление константных и пустых значений позволило сократить размерность данных на 12.5%.

ДИСБАЛАНС КЛАССОВ

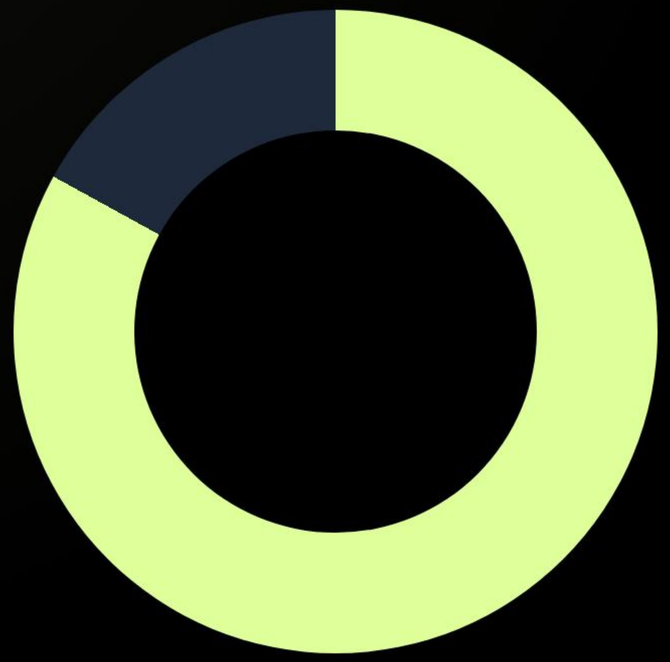

Attacks (17%)

Для корректного обучения модели потребуется применение алгоритмов балансировки (SMOTE/ADASYN).

ИТОГИ И ПЛАНЫ

- **Верифицированный набор:** Выборка в 94.8к записей полностью очищена от математических аномалий.
- **Минимизация FPR:** Удаление "битых" сессий снижает вероятность ложноположительных срабатываний.
- **ML-инференс:** Следующий шаг — обучение классификатора на базе отобранных 70 наиболее информативных признаков.

Вопросы?

Спасибо за внимание!

Проект по анализу CSE-CIC-IDS2018 | 2024

IMAGE SOURCES

https://static.vecteezy.com/system/resources/thumbnails/066/833/192/small/futuristic-digital-background-with-glowing-lines-and-circuit-elements-ideal-for-technology-data-and-cybersecurity-themes-hightech-style-with-green-light-abstract-design-illustration-vector.jpg

Source: www.vecteezy.com

Thumbnail for www.conceptdraw.com

https://www.conceptdraw.com/How-To-Guide/picture/Design%20Elements%20-%20AWS%20-%20Amazon%20Web%20Services%20architecture%20solution-2_0.png

Source: www.conceptdraw.com

---

https://swimlane.com/wp-content/uploads/SOC-BUILD_Masthead.png

Source: swimlane.com